

## BSG Institute

# Manipulación y Procesamiento de Datos con Python

### Tarea Sesión N° 05: Pandas y NumPy (dataset: train.csv, Ames Housing)

#### Objetivo:

- Familiarizarse con la biblioteca Pandas para el manejo de datos.
- Practicar la carga de datos desde diferentes fuentes (CSV, Excel).
- Aplicar métodos básicos de exploración de datos para entender la estructura y contenido de un dataset.
- Desarrollar habilidades para analizar datasets y responder preguntas específicas basadas en los datos.

#### Preguntas:

Cargue el dataset train.csv con pandas. Muestre su forma (shape) los tipos de datos por columna (dtypes) y el uso de memoria (df.info()).

Identifique cuántas variables son numéricas y cuántas categóricas usando select\_dtypes().

1. Calcule el porcentaje de valores faltantes por columna con `df.isnull().mean().sort_values(ascending=False)`. Liste las 10 variables con mayor porcentaje de valores nulos y clasifíquelas en: eliminar, imputar simple o imputar avanzado, justificando el criterio usado (porcentaje faltante y tipo de variable).
2. Variables indicadoras de valores faltantes (missing flags): Para al menos tres columnas con datos faltantes (por ejemplo LotFrontage, MasVnrType y FireplaceQu), cree una columna binaria adicional '<col>\_missing' usando `.isna().astype(int)`. Explique por qué esta práctica puede aportar información al modelo incluso después de imputar.
3. Imputación agrupada con groupby: Impute la variable LotFrontage utilizando la mediana calculada por grupo de Neighborhood (pista: `df.groupby('Neighborhood')['LotFrontage'].transform('median')`). Compare, mediante un histograma superpuesto, la distribución original (sin nulos) contra la distribución imputada.
4. Ingeniería de características (Feature Engineering): Cree al menos cuatro variables nuevas a partir de las existentes: TotalSF (suma de TotalBsmtSF, 1stFlrSF y 2ndFlrSF), HouseAge (YrSold - YearBuilt), RemodAge (YrSold -

YearRemodAdd) y TotalBath (FullBath + 0.5·HalfBath + BsmtFullBath + 0.5·BsmtHalfBath). Muestre las primeras 5 filas de estas nuevas columnas con `df[[...]].head()`.

**5. Pipeline de preprocesamiento con validación cruzada:**

Construya un Pipeline de scikit-learn que use ColumnTransformer para: (a) imputar valores numéricos con la mediana y escalar con RobustScaler, (b) imputar categóricos con la moda y aplicar One-Hot Encoding. Entrene un modelo (Ridge o RandomForestRegressor) sobre SalePrice y evalúe su desempeño con `cross_val_score` usando KFold (5 folds) y la métrica RMSE. Reporte el RMSE promedio y su desviación estándar.

**Instrucciones para la entrega**

- a. Cree un archivo Jupyter Notebook (.ipynb) con el nombre Tarea01\_Pandas\_NombreApellido.ipynb.
- b. Responda cada pregunta en una celda de código, incluyendo comentarios que expliquen el propósito de cada línea.
- c. Incluya una celda de texto (Markdown) después de cada pregunta con la respuesta escrita o interpretación de los resultados.
- d. Asegúrese de que el código sea ejecutable y que los resultados sean visibles en el notebook.